

Resumen Global y Hoja de Ruta: Fase Final

Proyecto: Elucidación Estructural RMN 1D/2D mediante Deep Learning

Estado: Resultados de Oráculos y Plan de Doble Regularización de 2026 **Fecha:** 12 de marzo de 2026

1. El Diagnóstico Crítico: Fuga de Datos y Línea Base

El hito metodológico primario de la fase de evaluación fue la detección de una vulnerabilidad de *Data Leakage* (Fuga de Datos). Al no compartir una semilla estocástica global, el conjunto de validación original contenía espectros ya observados durante el entrenamiento, inflando el rendimiento a un 89.26 %. Tras implementar un blindaje algorítmico estricto (`set_seed(42)`), se estableció el verdadero poder de generalización de la arquitectura base en **72.42 %**. Esta cifra representa la línea base real (Estado del Arte) a superar.

2. Tabla de Posiciones Real y Evolución de Modelos

Los modelos fueron sometidos a una evaluación rigurosa sobre espectros genuinamente desconocidos, introduciendo progresivamente conocimiento experto (*prior knowledge*).

Modelo	Condicionantes Inyectados	Exact Match Real
V3 (Base)	Suma Total de Señales	72.42 %
V4 (Fases)	Suma Total + HSQC de 2 Canales	69.86 %
V5 (Visual)	Suma Total + Suma de CH2	74.86 %
V6 (Masa Continua)	Suma Total + CH2 + Masa (Float)	74.11 %
V6.1 (Fórmula)	Suma Total + CH2 + [C,H,N,O,S,Ha1]	> 80.00 %*

*Validación en progreso, proyección teórica fundamentada.

3. Análisis de los Resultados: El Camino a Seguir

3.1. El Ideal Tecnológico vs. El Campeón Operativo

Desde la perspectiva de la autonomía algorítmica pura, el **Modelo V4** (HSQC de 2 canales) representa el *Ideal Tecnológico*, ya que no requiere intervención del operador para deducir las fases DEPT. Sin embargo, su bajo rendimiento (69.86 %) confirmó el fenómeno de *Modality Collapse*: la red encontró tan fácil resolver la imagen 2D segregada que se volvió "perezosa" y abandonó la optimización de la rama 1D, fallando en los carbonos invisibles.

Por otro lado, el **Modelo V5 (74.86 %)** se coronó como el *Campeón Operativo*. Logra un rendimiento superior exigiendo únicamente información trivial para un químico (contar las manchas de fase invertida en el espectro 2D).

4. Hoja de Ruta: Estrategia de Ataque Bifurcada

El objetivo final de la investigación es romper la barrera del 85 % en condiciones heréticas. Se abordará este desafío ejecutando un plan de optimización en paralelo para las dos arquitecturas más valiosas: **Resucitar el V4** y **Perfeccionar el V5**.

El obstáculo principal para ambos es el **Sobreajuste (Overfitting)** en el vector 1D (evidenciado por $\text{Train Loss} \sim 0,010$ vs $\text{Val Loss} \sim 0,045$).

4.1. Frente de Ataque 1: Perfeccionamiento del Modelo V5

Dado que el V5 ya posee la topología correcta, las acciones se centrarán en la regularización estática para maximizar la generalización:

- **Dropout Estratégico (0.25):** Se aplicará en las capas densas de fusión (`fc_fusion`) para forzar redundancia y evitar que subredes específicas memoricen el set de entrenamiento.
- **Weight Decay (L2 Regularization):** Inyección de una penalización (1×10^{-5}) en el optimizador Adam para suprimir pesos anómalamente grandes.

4.2. Frente de Ataque 2: Resurrección del Modelo V4 (Anti-Colapso)

Para obligar a la red multicanal a "despertar" prestar atención al vector 1D, se aplicarán técnicas dinámicas que dificulten la memorización espacial:

- **Data Augmentation 1D (Ruido Gaussiano Dinámico):** Adición de ruido estocástico microscópico a las proyecciones 1D en cada *epoch*. Si el 1D cambia sutilmente en cada iteración, la red no podrá ignorarlo.
- **Jittering Espectral:** Pequeños desplazamientos aleatorios (*shifts*) de píxeles en el vector 1D para forzar a la red a aprender vecindades topológicas y no índices absolutos, combatiendo directamente el colapso de modalidad.
- **Dropout Asimétrico:** Aplicar una tasa de *Dropout* agresiva exclusivamente a la rama de salida convolucional (2D), forzando a la red a depender de la rama densa (1D) para completar la información faltante.

5. Registro de Ejecuciones Activas (Pruebas en Curso)

De acuerdo con la hoja de ruta establecida, actualmente se encuentran en fase de entrenamiento en el clúster las siguientes iteraciones modificadas. Los resultados de estas pruebas determinarán si es necesario escalar el volumen del conjunto de datos.

5.1. Prueba 1: Modelo V5 Regularizado (Campeón Operativo)

Se implementaron modificaciones estáticas para penalizar la co-adaptación neuronal y frenar el sobreajuste evidenciado en el modelo original (74.86 %).

- **Arquitectura** (`model_v5.py`): Se inyectaron dos capas de `nn.Dropout(p=0.25)` inmediatamente después de las activaciones ReLU en `fc_fusion1` y `fc_fusion2`.
- **Optimizador** (`train_v5.py`): Se añadió el parámetro `weight_decay=1e-5` al optimizador Adam (Regularización L2).

5.2. Prueba 2: Modelo V4 Anti-Colapso (Ideal Tecnológico)

Se aplicó un esquema de penalización asimétrica y aumento de datos dinámico para mitigar la pereza algorítmica producida por la separación en dos canales del HSQC original (69.86 %).

- **Castigo a la Modalidad Visual** (`model_v4.py`): Se insertó un `nn.Dropout` agresivo (50 %) al final de la rama convolucional 2D, antes de la concatenación.
- **Aumento de Datos Dinámico** (`train_v4.py`): Inyección de ruido gaussiano $\mathcal{N}(0, \sigma = 0,015)$ y *Spectral Jittering* (`torch.roll` aleatorio entre -2 y $+2$) en el vector 1D por cada iteración.
- **Regularización General**: `nn.Dropout(p=0.25)` en fusión y `weight_decay=1e-5` en optimizador.

5.3. Prueba 3: Modelo V6.1 Regularizado (Oráculo de Fórmula Real)

Tras confirmar que la inyección de la fórmula explícita (`[C, H, N, O, S, Hal]`) acelera drásticamente la convergencia, se somete a este modelo oráculo a las mismas técnicas de regularización estática que el V5 para evitar el sobreajuste temprano.

- **Modificaciones**: `nn.Dropout(p=0.25)` en las capas de fusión y `weight_decay=1e-5` en el optimizador Adam.
- **Objetivo Teórico**: Establecer el límite absoluto del rendimiento de la arquitectura convolucional cuando se dispone de información analítica completa (MS de alta resolución y DEPT), dictaminando si el techo del $\sim 85\%$ es franqueable sin aumentar el tamaño de la base de datos.