

Proyecto: Elucidación Estructural RMN 1D/2D mediante Deep Learning

Reporte Comparativo de Evaluación

Modelos $V3 \rightarrow V4 \rightarrow V5 \rightarrow V6$

Lucas Passaglia

13 de Marzo 2026

Contents

1	Resumen Ejecutivo y Comparativa Global	2
2	Arquitectura Común de la Red	2
3	Modelo V3 — Modelo Base (72.42%)	3
3.1	Descripción	3
3.2	Resultados de Evaluación	3
4	Modelo V4 — Modelo Ideal con Espectro de 2 Canales (69.86%)	4
4.1	Descripción y Motivación	4
4.2	Resultados de Evaluación	4
4.3	Análisis del Resultado	4
5	Modelo V5 — Modelo Base con Input de CH_2 (74.86%)	5
5.1	Descripción	5
5.2	Resultados de Evaluación	5
6	Modelo V6 — Modelo Completo con Fórmula Molecular (79.54%)	6
6.1	Descripción	6
6.2	Resultados de Evaluación	6
6.3	Matrices de Confusión de Multiplicidad	7
7	Análisis Comparativo entre Versiones	7
7.1	Evolución del MAE por grupo	7
7.2	Evolución del error por entorno	8
7.3	Evolución del error de multiplicidad	8
8	Conclusiones y Hoja de Ruta	9
8.1	Logros Globales del Proyecto	9
8.2	Estrategias para Superar el 85%	9


1 Resumen Ejecutivo y Comparativa Global

Este reporte consolida los resultados de evaluación de los cuatro modelos entrenados sobre el dataset de **144.280 moléculas** (set de validación: 14.428). Todos los modelos fueron evaluados bajo condiciones herméticas (semilla fija `set.seed(42)`), garantizando que el set de validación no fue observado durante el entrenamiento.

Table 1: Comparativa global de rendimiento por versión de modelo

Modelo	Condicionantes inyectados	EMA	Δ base	Err. mult.
V3 — base	Espectros + total de señales	72.42%	—	1.1%
V4 — ideal (2 canales)	Espectros 2 canales + total de señales	69.86%	−2.56 pp	—*
V5 — base + CH ₂	Espectros + total señales + total CH ₂	74.86%	+2.44 pp	0.8%
V6 — completo (+ FM)	Espectros + total señales + CH ₂ + FM	79.54%	+7.12 pp	0.6%
Objetivo del proyecto		>85%		

*El análisis completo de errores del V4 no está disponible (ver Sección 4).



2 Arquitectura Común de la Red

Todos los modelos comparten la misma arquitectura base de **dos ramas** que se fusionan en capas densas:

- **Rama convolucional (HSQC):** 3 bloques Conv2D (1→16→32→64 filtros, kernel 3×3) + MaxPool2D(2×2). Salida aplanada: $64 \times 32 \times 32 = 65.536$ neuronas.
- **Rama densa 1D (proyecciones):** Vector de 512 posiciones (`vec_C` + `vec_H`) → 256 → 128 neuronas.
- **Tensor condicional:** Variable según la versión (ver cada sección).

- **Fusión:** Concatenación de las tres ramas $\rightarrow 128 \rightarrow 64 \rightarrow 13$ salidas.

Función de pérdida común (ConstrainedMSELoss):

$$\mathcal{L} = \text{MSE}(\hat{\mathbf{y}}, \mathbf{y}) + 0.5 \cdot \text{MSE}(\sum_i \hat{y}_i, \sum_i y_i) \quad (1)$$

3 Modelo V3 — Modelo Base (72.42%)

3.1 Descripción

El Modelo V3 es el **modelo base** del proyecto. Utiliza el espectro HSQC de 1 canal junto con las proyecciones 1D (vec_C + vec_H), condicionado por un único escalar: el total de señales de la molécula. No incluye regularización adicional. Este modelo establece la línea base real tras corregir la fuga de datos detectada en evaluaciones anteriores.

Condicionante: [Total de señales] (1 valor).

3.2 Resultados de Evaluación

Table 2: MAE por grupo — Modelo V3 (EMA: 72.42%)

Grupo	Descripción	MAE	Estado
CH ₃	Metilo alifático	0.0161	Excelente
CH ₂	Metileno alifático	0.0444	Excelente
CH	Metino alifático	0.0381	Excelente
C _q	Cuaternario alifático	0.0299	Excelente
CH ₃ -X	Metilo heteroatómico	0.0147	Excelente
CH ₂ -X	Metileno heteroatómico	0.0391	Excelente
CH-X	Metino heteroatómico	0.0434	Excelente
C _q -X	Cuaternario heteroatómico	0.0448	Excelente
=CH ₂	Metileno vinílico	0.0046	Excelente
=CH/Ar	Aromático CH	0.0647	Aceptable
=C _q /Ar	Cuaternario arom.	0.1663	Mejorable
Aldeh.	Aldehído (CHO)	0.0145	Excelente
C=O	Carbonilo	0.1198	Mejorable

Table 3: Errores por entorno químico — V3

Entorno	Mol. con error	%	MAE medio
Alifáticos (sp ³)	1.530	10.6%	0.0321
Heteroatómicos (sp ³ -X)	1.798	12.5%	0.0355
Insaturados / Aromáticos	2.812	19.5%	0.0786
Carbonílicos	1.829	12.7%	0.0672

Error de multiplicidad: 161 moléculas (1.1%). Los errores más frecuentes son CH $\rightarrow$ CH₃ (45 señales) y CH-X $\rightarrow$ CH₃-X (26 señales).

Principal confusión cruzada: $\text{C=O} \rightarrow \text{=C}_q/\text{Ar}$ (794 señales, 79.2% del error de C=O). Esta confusión bidireccional $\text{=C}_q/\text{Ar} \leftrightarrow \text{C=O}$ ya aparece como el cuello de botella dominante desde la línea base.

4 Modelo V4 — Modelo Ideal con Espectro de 2 Canales (69.86%)

4.1 Descripción y Motivación

El V4 es el **modelo ideal** del proyecto en términos de autonomía: utiliza el espectro HSQC separado en **2 canales** para que la red deduzca automáticamente la información de multiplicidad sin intervención del operador. Canal 1 contiene las señales positivas (CH , CH_3); Canal 2 contiene el valor absoluto de las señales negativas (CH_2). La rama convolucional acepta por tanto tensores de shape (2, 256, 256).

El resto de la arquitectura es idéntico al V3: proyecciones 1D ($\text{vec}_C + \text{vec}_H$), condicionante escalar de total de señales, y capas de fusión con Dropout (0.25) y Weight Decay (10^{-5}).

Condicionante: [Total de señales] (1 valor). **HSQC:** 2 canales (en lugar de 1).

4.2 Resultados de Evaluación

Table 4: MAE por grupo — Modelo V4 (EMA: 69.86%)

Grupo	Descripción	MAE	Estado
CH_3	Metilo alifático	0.0195	Excelente
CH_2	Metileno alifático	0.0532	Aceptable
CH	Metino alifático	0.0442	Excelente
C_q	Cuaternario alifático	0.0347	Excelente
$\text{CH}_3\text{-X}$	Metilo heteroatómico	0.0166	Excelente
$\text{CH}_2\text{-X}$	Metileno heteroatómico	0.0461	Excelente
CH-X	Metino heteroatómico	0.0473	Excelente
$\text{C}_q\text{-X}$	Cuaternario heteroatómico	0.0449	Excelente
=CH_2	Metileno vinílico	0.0050	Excelente
=CH/Ar	Aromático CH	0.0657	Aceptable
$\text{=C}_q/\text{Ar}$	Cuaternario arom.	0.1819	Mejorable
Aldeh.	Aldehído (CHO)	0.0153	Excelente
C=O	Carbonilo	0.1348	Mejorable

Nota: el análisis detallado de errores por entorno y confusión de multiplicidad no está disponible para este modelo.

4.3 Análisis del Resultado

El V4 registra la **peor EMA de la serie** (69.86%), siendo 2.56 pp inferior al modelo base V3 a pesar de disponer de más información espectral. El fenómeno observado es el **colapso de modalidad**: la red encontró que la imagen 2D segregada era tan informativa para los carbonos con H que se volvió “perezosa” y dejó de optimizar la rama 1D. Esto perjudica especialmente a los carbonos cuaternarios (C_q , C=O , $\text{=C}_q/\text{Ar}$), que son **invisibles en HSQC** por definición y que la red ya no aprendió a inferir desde el vector 1D.

Los MAE de $=C_q/Ar$ (0.1819) y $C=O$ (0.1348) son los peores de toda la serie de modelos, confirmando este mecanismo. En contraste, los grupos con H visible en HSQC (CH_3 , CH , CH_3-X) muestran MAE comparables al V3.

La arquitectura de 2 canales sigue siendo el objetivo ideal del proyecto. La solución al colapso de modalidad requiere un enfoque de entrenamiento progresivo (*Curriculum Learning*) más que modificaciones en la arquitectura.

5 Modelo V5 — Modelo Base con Input de CH_2 (74.86%)

5.1 Descripción

El V5 retoma la arquitectura del modelo base (V3, HSQC 1 canal), añadiendo un **segundo condicionante escalar**: el total de señales CH_2 genéricas (posiciones 1, 5 y 8 del vector objetivo, correspondientes a CH_2 , CH_2-X y $=CH_2$). Esta información es obtenible por un químico contando las manchas de fase invertida en el espectro DEPT o HSQC editado.

Condicionante: [Total de señales, Total CH_2] (2 valores).

5.2 Resultados de Evaluación

Table 5: MAE por grupo — Modelo V5 (EMA: 74.86%)

Grupo	Descripción	MAE	Estado
CH_3	Metilo alifático	0.0156	Excelente
CH_2	Metileno alifático	0.0341	Excelente
CH	Metino alifático	0.0365	Excelente
C_q	Cuaternario alifático	0.0305	Excelente
CH_3-X	Metilo heteroatómico	0.0112	Excelente
CH_2-X	Metileno heteroatómico	0.0381	Excelente
$CH-X$	Metino heteroatómico	0.0390	Excelente
C_q-X	Cuaternario heteroatómico	0.0396	Excelente
$=CH_2$	Metileno vinílico	0.0040	Excelente
$=CH/Ar$	Aromático CH	0.0536	Aceptable
$=C_q/Ar$	Cuaternario arom.	0.1487	Mejorable
Aldeh.	Aldehído (CHO)	0.0115	Excelente
$C=O$	Carbonilo	0.1123	Mejorable

Table 6: Errores por entorno químico — V5

Entorno	Mol. con error	%	MAE medio
Alifáticos (sp^3)	1.423	9.9%	0.0292
Heteroatómicos (sp^3-X)	1.648	11.4%	0.0320
Insaturados / Aromáticos	2.504	17.4%	0.0688
Carbonílicos	1.694	11.7%	0.0619

Error de multiplicidad: 116 moléculas (0.8%). Mejora de 0.3 pp respecto al V3. Las confusiones dominantes siguen siendo $CH \rightarrow CH_3$ (37 señales) y $CH-X \rightarrow CH_3-X$ (19 señales).

Principal confusión cruzada: $\text{C=O} \rightarrow \text{=C}_q/\text{Ar}$ (603 señales, 80.4%). El condicionante de CH_2 redujo los errores en los metilenos ($\text{CH}_2\text{-X} \rightarrow \text{CH}_2$ bajó de 219 a 261 añ todavía alto pero con mejor distribución). El cuello de botella en $\text{=C}_q/\text{Ar}$ y C=O persiste sin resolución.

6 Modelo V6 — Modelo Completo con Fórmula Molecular (79.54%)

6.1 Descripción

El V6 es la arquitectura más completa. Sobre la base del V5, añade la **fórmula molecular explícita** [*C*, *H*, *N*, *O*, *S*, Hal] extraída desde los SMILES mediante RDKit, completando el tensor condicional a 8 valores. Incorpora además regularización completa (Dropout 0.25 en ambas capas de fusión + Weight Decay 10^{-5}).

Condicionante: [Total señales, Total CH_2 , *C*, *H*, *N*, *O*, *S*, Hal] (8 valores). FM = Fórmula Molecular.

6.2 Resultados de Evaluación

79.54% Exact Match Accuracy (EMA)

Table 7: MAE por grupo — Modelo V6 (EMA: 79.54%)

Grupo	Descripción	MAE	Estado
CH_3	Metilo alifático	0.0116	Excelente
CH_2	Metileno alifático	0.0292	Excelente
CH	Metino alifático	0.0304	Excelente
C_q	Cuaternario alifático	0.0268	Excelente
$\text{CH}_3\text{-X}$	Metilo heteroatómico	0.0110	Excelente
$\text{CH}_2\text{-X}$	Metileno heteroatómico	0.0331	Excelente
CH-X	Metino heteroatómico	0.0308	Excelente
$\text{C}_q\text{-X}$	Cuaternario heteroatómico	0.0365	Excelente
$=\text{CH}_2$	Metileno vinílico	0.0034	Excelente
$=\text{CH/Ar}$	Aromático CH	0.0462	Excelente
$=\text{C}_q/\text{Ar}$	Cuaternario arom.	0.1141	Mejorable
Aldeh.	Aldehído (CHO)	0.0116	Excelente
C=O	Carbonilo	0.0742	Aceptable

Table 8: Errores por entorno químico — V6

Entorno	Mol. con error	%	MAE medio
Alifáticos (sp^3)	1.225	8.5%	0.0245
Heteroatómicos ($\text{sp}^3\text{-X}$)	1.433	9.9%	0.0278
Insaturados / Aromáticos	1.958	13.6%	0.0546
Carbonílicos	1.168	8.1%	0.0429

Error de multiplicidad: 86 moléculas (0.6%), el menor de todos los modelos. Tasa de acierto sobre señales CH_n : **100.0%** tanto en alifáticos como heteroatómicos.

Logro clave: C=O pasa de *Mejorable* (V5: 0.1123) a *Aceptable* (V6: 0.0742), gracias a que la fórmula molecular provee información directa sobre la cantidad de oxígenos. El único grupo que permanece mejorable es =Cq/Ar (0.1141).

6.3 Matrices de Confusión de Multiplicidad

Table 9: Confusión de multiplicidad alifática — V6

	Pred. CH_3	Pred. CH_2	Pred. CH
Real CH_3	14.684	4	13
Real CH_2	1	22.663	4
Real CH	29	11	14.077

Table 10: Confusión de multiplicidad heteroatómica — V6

	Pred. $\text{CH}_3\text{-X}$	Pred. $\text{CH}_2\text{-X}$	Pred. CH-X
Real $\text{CH}_3\text{-X}$	4.583	2	10
Real $\text{CH}_2\text{-X}$	2	8.055	6
Real CH-X	12	6	3.679

7 Análisis Comparativo entre Versiones

7.1 Evolución del MAE por grupo

La Tabla 11 permite seguir la evolución de cada grupo funcional a través de las versiones. Los grupos con fondo verde mejoraron respecto al V3; los con fondo rojo empeoraron.

Table 11: Comparativa de MAE por grupo (V3 $\rightarrow$ V4 $\rightarrow$ V5 $\rightarrow$ V6)

Grupo	V3	V4	V5	V6	Δ (V3 $\rightarrow$ V6)
CH ₃	0.0161	0.0195	0.0156	0.0116	−27.9%
CH ₂	0.0444	0.0532	0.0341	0.0292	−34.2%
CH	0.0381	0.0442	0.0365	0.0304	−20.2%
C _q	0.0299	0.0347	0.0305	0.0268	−10.4%
CH ₃ -X	0.0147	0.0166	0.0112	0.0110	−25.2%
CH ₂ -X	0.0391	0.0461	0.0381	0.0331	−15.3%
CH-X	0.0434	0.0473	0.0390	0.0308	−29.0%
C _q -X	0.0448	0.0449	0.0396	0.0365	−18.5%
=CH ₂	0.0046	0.0050	0.0040	0.0034	−26.1%
=CH/Ar	0.0647	0.0657	0.0536	0.0462	−28.6%
=C _q /Ar	0.1663	0.1819	0.1487	0.1141	−31.4%
Aldeh.	0.0145	0.0153	0.0115	0.0116	−20.0%
C=O	0.1198	0.1348	0.1123	0.0742	−38.1%

El avance es consistente en **todos los grupos**, con mejoras de entre 10% y 38% respecto a la línea base. El mayor salto individual es en C=O (−38.1%), atribuible a la inyección del número de oxígenos en la fórmula molecular.

7.2 Evolución del error por entorno

Table 12: Porcentaje de moléculas con error por entorno (V3 $\rightarrow$ V5 $\rightarrow$ V6)

Entorno	V3	V5	V6	Mejora V3 $\rightarrow$ V6
Alifáticos (sp ³)	10.6%	9.9%	8.5%	−2.1 pp
Heteroatómicos (sp ³ -X)	12.5%	11.4%	9.9%	−2.6 pp
Insaturados / Aromáticos	19.5%	17.4%	13.6%	−5.9 pp
Carbonílicos	12.7%	11.7%	8.1%	−4.6 pp

7.3 Evolución del error de multiplicidad

Table 13: Error de multiplicidad por versión

Modelo	Mol. afectadas	%	Mejora
V3	161	1.1%	—
V5	116	0.8%	−0.3 pp
V6	86	0.6%	−0.5 pp

La confusión de multiplicidad es ya marginal en todos los modelos y prácticamente resuelta en el V6. El problema residual del proyecto se concentra exclusivamente en la ambigüedad =C_q/Ar $\leftrightarrow$ C=O.

8 Conclusiones y Hoja de Ruta

8.1 Logros Globales del Proyecto

- Se estableció una **línea base sólida y reproducible** (V3: 72.42%) tras corregir la fuga de datos.
- Agregar el conteo de CH₂ como input (V5) ya aportó una mejora real (+2.44 pp). La inyección de la fórmula molecular completa (V6) produjo el mayor salto (+7.12 pp), confirmando que el **conocimiento químico explícito como condicionante** es la estrategia más efectiva.
- **12 de 13 grupos** resueltos con MAE excelente o aceptable en el V6. La confusión de multiplicidad (CH/CH₂/CH₃) es prácticamente nula (0.6%).
- El V4 (modelo ideal de 2 canales) sufrió colapso de modalidad, pero su arquitectura sigue siendo la meta: un modelo que no requiere ningún input del operador.
- El **cuello de botella único** está identificado con precisión: la confusión bidireccional =Cq/Ar $\leftrightarrow$ C=O, ambos carbonos cuaternarios invisibles en HSQC con desplazamientos ¹³C solapados (100–165 ppm).

8.2 Estrategias para Superar el 85%

1. **Inyección del DBE** (Grado de Insaturación, derivable de la fórmula ya disponible): diferencia directamente entre anillos aromáticos y grupos C=O.
2. **Pérdida asimétrica** para grupos invisibles: aumentar λ para =Cq/Ar y C=O dentro de la ConstrainedMSELoss.
3. **Resolver el V4** con Curriculum Learning: pre-entrenar la rama 1D antes de activar el HSQC de 2 canales, evitando el colapso de modalidad.
4. **Ampliar el dataset** a ~500k moléculas si el techo arquitectónico actual resulta insuficiente.
5. **HMBC simulado** como entrada opcional: proveería evidencia directa sobre la conectividad de carbonos cuaternarios.