

Proyecto: Elucidación Estructural RMN 1D/2D mediante Deep Learning

Reporte Comparativo de Evaluación

Modelos V3 $\rightarrow$ V6 (12 clases)

Lucas Passaglia

Marzo 2026

Contents


1	Resumen Ejecutivo	1
2	Arquitectura Común y Progreso de Modelos	2
2.1	Evolución de condicionantes y resultados	2
3	Mejor Modelo: V6 con 12 Clases (83.79%)	3
3.1	Motivación: Fusión de =Cq/Ar y C=O en Cqsp2	3
3.2	Doble Restricción en el Postprocesamiento	3
3.3	Convergencia del Entrenamiento	4
3.4	MAE por Grupo	4
4	Análisis de Errores del Mejor Modelo	4
4.1	Errores de Multiplicidad	5
4.2	Errores de Entorno Químico	6
5	Conclusiones y Próximos Pasos	7
5.1	Hitos del Proyecto	7
5.2	Próximos Pasos para Superar el 85%	7

1 Resumen Ejecutivo

Este reporte muestra los resultados de los modelos entrenados sobre **144.280 moléculas** (set de validación hermético: 14.428, semilla fija `set.seed(42)`). La métrica principal es el **Exact Match Accuracy (EMA)**: porcentaje de moléculas cuyo vector de grupos funcionales es predicho perfectamente.

Table 1: Serie completa de modelos

Modelo	Condicionantes inyectados	EMA	Δ base	Clases
V3 — base	Espectros + total señales	72.42%	—	13
V4 — 2 canales	Espectros 2 canales + total señales	69.86%	−2.56 pp	13
V5 — base + CH ₂	Espectros + total señales + total CH ₂	74.86%	+2.44 pp	13
V6 — completo (+ FM)	Espectros + total señales + CH ₂ + FM	79.54%	+7.12 pp	13
V6 12v — simple	V6 + fusión Cqsp2 (=Cq/Ar + C=O)	83.74%	+11.32 pp	12
V6 12v — doble restr.	V6 + fusión Cqsp2 + ajuste CH ₂	83.79%	+11.37 pp	12
<i>Objetivo del proyecto</i>		>85%		



2 Arquitectura Común y Progreso de Modelos

Todos los modelos comparten la misma arquitectura base de **dos ramas**: una rama convolucional para el HSQC (3× Conv2D con 16→32→64 filtros + MaxPool, salida aplanada de 65.536 neuronas) y una rama densa para las proyecciones 1D (**vec_C** + **vec_H**, 512→256→128 neuronas). Ambas se concatenan junto a un **tensor condicional** variable y pasan por capas densas de fusión. La función de pérdida penaliza el error individual por grupo y la desviación en el total de señales:

$$\mathcal{L} = \text{MSE}(\hat{\mathbf{y}}, \mathbf{y}) + 0.5 \cdot \text{MSE}(\sum_i \hat{y}_i, \sum_i y_i) \quad (1)$$

2.1 Evolución de condicionantes y resultados

Cada versión añadió conocimiento químico explícito como condicionante, siendo esa la palanca más efectiva de mejora a lo largo de la serie.

V3 (72.42%) — condicionante mínimo: solo el total de señales de la molécula. Establece la línea base real tras corregir la fuga de datos que inflaba artificialmente el rendimiento a

89.26%. Los dos grupos problemáticos ya son $\text{=C}_q/\text{Ar}$ (MAE 0.166) y C=O (MAE 0.120), ambos invisibles en HSQC.

V4 (69.86%) — HSQC de 2 canales: señales positivas (CH , CH_3) y negativas en valor absoluto (CH_2). Peor resultado de la serie por *colapso de modalidad*: la imagen segregada resuelve sola los carbonos con H y la red deja de optimizar la rama 1D. Los carbonos cuaternarios e invisibles en HSQC empeoran notablemente ($\text{=C}_q/\text{Ar}$ sube a MAE 0.182). La arquitectura 2 canales sigue siendo el ideal a largo plazo; requiere *Curriculum Learning*.

V5 (74.86%) — segundo condicionante: total de señales CH_2 (conteo de manchas de fase invertida, trivial para un químico). Mejora de +2.44 pp.

V6 (79.54%) — fórmula molecular completa $[C, H, N, O, S, \text{Hal}]$ extraída vía RDKit, más regularización (Dropout 0.25 + Weight Decay 10^{-5}). Mayor salto de la serie (+7.12 pp). C=O pasa a *Acceptable* (MAE 0.074); $\text{=C}_q/\text{Ar}$ permanece mejorable (MAE 0.114).

Table 2: Comparativa de MAE por grupo (V3 $\rightarrow$ V6)

Grupo	V3	V4	V5	V6	Δ V3 $\rightarrow$ V6
CH_3	0.0161	0.0195	0.0156	0.0116	−27.9%
CH_2	0.0444	0.0532	0.0341	0.0292	−34.2%
CH	0.0381	0.0442	0.0365	0.0304	−20.2%
C_q	0.0299	0.0347	0.0305	0.0268	−10.4%
$\text{CH}_3\text{-X}$	0.0147	0.0166	0.0112	0.0110	−25.2%
$\text{CH}_2\text{-X}$	0.0391	0.0461	0.0381	0.0331	−15.3%
CH-X	0.0434	0.0473	0.0390	0.0308	−29.0%
$\text{C}_q\text{-X}$	0.0448	0.0449	0.0396	0.0365	−18.5%
=CH_2	0.0046	0.0050	0.0040	0.0034	−26.1%
=CH/Ar	0.0647	0.0657	0.0536	0.0462	−28.6%
$\text{=C}_q/\text{Ar}$	0.1663	0.1819	0.1487	0.1141	−31.4%
Aldeh.	0.0145	0.0153	0.0115	0.0116	−20.0%
C=O	0.1198	0.1348	0.1123	0.0742	−38.1%

3 Mejor Modelo: V6 con 12 Clases (83.79%)

3.1 Motivación: Fusión de $\text{=C}_q/\text{Ar}$ y C=O en Cqsp2

El análisis del V6 mostró que la confusión $\text{=C}_q/\text{Ar} \leftrightarrow \text{C=O}$ concentraba el 53–80% del error de ambos grupos. Ambos comparten: invisibilidad en HSQC (carbonos cuaternarios sp^2 sin H), desplazamiento ^{13}C solapado en la región 100–165 ppm, y ausencia de discriminador disponible con la información espectral provista. Se decidió **fusionarlos en Cqsp2** (carbono cuaternario sp^2), reduciendo el vector de 13 a 12 clases y aportando +4.25 pp de EMA.

3.2 Doble Restricción en el Postprocesamiento

Se implementó un ajuste con doble restricción dura sobre la predicción cruda: (1) forzar que $\text{CH}_2 + \text{CH}_2\text{-X} + \text{=CH}_2$ sumen exactamente `total_ch2`, y (2) forzar que los 9 grupos restantes sumen `total_señales − total_ch2`. La doble restricción sumó solo +0.05 pp sobre la simple (83.74% $\rightarrow$ 83.79%), confirmando que el modelo ya absorbió internamente el condicionante de CH_2 .

3.3 Convergencia del Entrenamiento

El entrenamiento fue interrumpido a los 61 epochs por límites del clúster, pero el mejor checkpoint se obtuvo en el epoch 42 (Val Loss: 0.0297). Desde el epoch 47 el val loss se estabilizó en ~ 0.0307 con $LR \rightarrow 0.000031$ sin mejora adicional posible.

Table 3: Evolución del entrenamiento V6 12 clases

Epoch	Train Loss	Val Loss	Nota
1	0.8670	0.2046	
10	0.0341	0.0397	
32	0.0121	0.0307	
42	0.0067	0.0297	Mejor checkpoint
54	0.0042	0.0307	LR = 0.000063 (plateau)
61	0.0037	0.0307	Job interrumpido

3.4 MAE por Grupo

83.79% EMA — V6 12 clases (doble restricción)

Table 4: MAE por grupo — V6 12 clases (EMA: 83.79%)

Grupo	Descripción	MAE	Estado
CH ₃	Metilo alifático	0.0122	Excelente
CH ₂	Metileno alifático	0.0358	Excelente
CH	Metino alifático	0.0321	Excelente
C _q	Cuaternario alifático	0.0279	Excelente
CH ₃ -X	Metilo heteroatómico	0.0122	Excelente
CH ₂ -X	Metileno heteroatómico	0.0385	Excelente
CH-X	Metino heteroatómico	0.0349	Excelente
C _q -X	Cuaternario heteroatómico	0.0404	Excelente
=CH ₂	Metileno vinílico	0.0037	Excelente
=CH/Ar	Aromático / Vinílico CH	0.0476	Excelente
Cqsp2	Cuaternario sp ² (arom. + olef. + C=O)	0.0618	Aceptable
Aldeh.	Aldehído (CHO)	0.0119	Excelente

Hito: Por primera vez, **todos los grupos están por debajo de MAE 0.1**. El único grupo aceptable (Cqsp2) es consecuencia directa de la fusión de clases.

4 Análisis de Errores del Mejor Modelo

Los errores residuales del V6 12 clases se clasifican en dos categorías con causas y soluciones distintas:

- **Errores de multiplicidad:** se predice el entorno correctamente pero no el número de H (CH vs CH₂ vs CH₃). Son químicamente los más graves porque implican proponer una subestructura errónea.
- **Errores de entorno:** se predice bien la multiplicidad pero se falla en el entorno del carbono (alifático puro vs heteroatómico, sp² vs sp³). Menos graves: la conectividad está bien, pero el desplazamiento químico esperado difiere.

4.1 Errores de Multiplicidad

Table 5: Moléculas con al menos un error de multiplicidad (serie completa)

Modelo	Mol. afectadas	%	Tendencia
V3 (base, 13 clases)	161	1.1%	línea base
V5 (+ CH ₂)	116	0.8%	−0.3 pp
V6 (completo, 13 clases)	86	0.6%	−0.5 pp
V6 12v (doble restricción)	104	0.7%	prácticamente resuelto

El nivel de 0.7% (104 moléculas sobre 14.428) es **prácticamente nulo**. Las matrices siguientes muestran la distribución de señales correctamente asignadas (diagonal, fondo azul) y los errores de multiplicidad puros (fuera de diagonal), sobre el total del set de validación.

Table 6: Matriz de confusión de multiplicidad — entorno alifático (sp³, sin heteroátomo)

	Pred. CH ₃	Pred. CH ₂	Pred. CH	Total real
Real CH₃	14.684	4	13	14.701
Real CH₂	1	22.663	4	22.668
Real CH	29	11	14.077	14.117
Precisión de fila	99.8%	99.9%	99.7%	

Table 7: Matriz de confusión de multiplicidad — entorno heteroatómico (sp³-X)

	Pred. CH ₃ -X	Pred. CH ₂ -X	Pred. CH-X	Total real
Real CH₃-X	4.583	2	10	4.595
Real CH₂-X	2	8.055	6	8.063
Real CH-X	12	6	3.679	3.697
Precisión de fila	99.7%	99.9%	99.5%	

La precisión de multiplicidad supera el 99.5% en todos los casos. Los pocos errores que ocurren son consistentes: CH→CH₃ es la confusión más frecuente, lo que sugiere un sesgo residual menor hacia clases más frecuentes en el dataset. No hay confusión significativa entre CH₂ y CH, ni entre CH₃ y CH₂, lo que confirma que el modelo distingue correctamente los grupos por número de H.

4.2 Errores de Entorno Químico

Aclaración sobre los números de esta sección. El EMA de 83.79% significa que 12.098 de las 14.428 moléculas son predichas perfectamente. Las 2.330 moléculas restantes tienen al menos un grupo erróneo en algún entorno. La tabla siguiente cuenta cuántas de esas 2.330 moléculas tienen un error en cada tipo de entorno — como una molécula puede tener tanto carbonos alifáticos como heteroatómicos, los conteos se solapan y no suman 2.330.

Table 8: Moléculas con al menos un error en cada entorno — V6 12 clases

Entorno	Mol. con error	%	MAE medio	Mol. sin error
Alifáticos (sp^3)	1.349	9.3%	0.0270	90.7%
Heteroatómicos (sp^3 -X)	1.627	11.3%	0.0315	88.7%
Carbonos sp^2 (Cqsp2, =CH/Ar, Aldeh.)	1.295	9.0%	0.0313	91.0%
Moléculas perfectas (EMA)	12.098	83.79%		

Los tres entornos están equilibrados (9–11%) y son consistentes con el EMA: son moléculas que fallaron en alguno de sus muchos grupos, no moléculas donde todo el entorno esté mal predicho. El entorno sp^2 bajó del 13.6% del V6 original al 9.0% gracias a la fusión de Cqsp2.

Mapa de confusiones cruzadas. Cuando el modelo falla en un grupo, la siguiente tabla muestra con qué otro grupo lo confunde. Los porcentajes indican *del total de señales mal asignadas de ese grupo, cuántas van a parar a otro grupo específico* — no el porcentaje de todas las señales del grupo. Se incluye el total de señales reales como denominador para dar contexto sobre la magnitud real del error.

Table 9: Confusiones cruzadas de entorno: cuando el modelo falla en X, *por dónde falla*

Real	Predicho	Señ. mal	Total real	% error/total	Tipo
CH ₂	CH ₂ -X	283	~22.700	1.2%	alifát. → heteroat.
CH ₂ -X	CH ₂	277	~8.100	3.4%	heteroat. → alifát.
CH	CH-X	137	~14.100	1.0%	alifát. → heteroat.
CH-X	CH	131	~3.700	3.5%	heteroat. → alifát.
Cq-X	Cqsp2	212	~4.300	4.9%	sp^3 -X → sp^2
Cq-X	C _q	132	~4.300	3.1%	heteroat. → alifát.
Cqsp2	Cq-X	154	~8.200	1.9%	sp^2 → sp^3 -X
Cqsp2	=CH/Ar	130	~8.200	1.6%	cuatern. → CH
=CH/Ar	Cqsp2	173	~9.700	1.8%	CH → cuatern.
Aldeh.	=CH/Ar	114	~1.700	6.7%	despl. ¹ H solapado

La columna **% error/total** es la que realmente importa: muestra qué fracción del total de señales de ese grupo está mal asignada hacia ese destino. La mayoría está entre 1% y 5%, lo que es coherente con el EMA de 83.79%.

Patrones y causas:

1. Confusión alifático ↔ heteroatómico (rojo, ~1–3.5% de las señales): CH₂/CH₂-X y CH/CH-X se intercambian bidireccionalmente. Es el patrón dominante pero a escala real afecta poco más del 1–3% de las señales de cada grupo. El HSQC informa el desplazamiento

químico del carbono, que se solapa entre entornos; la fórmula molecular no indica la conectividad a heteroátomos. **No es resoluble con los datos actuales.**

2. Cq-X confundido con Cqsp2 (4.9%) o con Cq (3.1%): los carbonos cuaternarios heteroatómicos sin H tienen desplazamientos que cruzan tanto la región sp^2 como la alifática según el heteroátomo involucrado. Consecuencia directa de la fusión de Cqsp2.

3. Cqsp2 $\leftrightarrow$ =CH/Ar (~ 1.6 – 1.8%): confusión de multiplicidad *dentro* del entorno sp^2 : cuaternario vs carbono con H. Porcentaje bajo, esperable tras la fusión.

4. Aldeh. $\rightarrow$ =CH/Ar (6.7%): el mayor error por unidad de señal. Los aldehídos ($\delta^1H \approx 9$ – 10 ppm) solapan con aromáticos desapantallados. Afecta relativamente pocas señales en total (~ 114) porque los aldehídos son poco frecuentes en el dataset.

5 Conclusiones y Próximos Pasos

5.1 Hitos del Proyecto

- **83.79% EMA:** máximo absoluto, a 1.21 pp del objetivo de 85%.
- **Todos los grupos por debajo de MAE 0.1** por primera vez.
- La inyección de conocimiento químico explícito como condicionante fue la estrategia más efectiva en cada iteración.
- El error de multiplicidad (CH/CH₂/CH₃) está prácticamente resuelto ($>99.5\%$ de precisión). El error residual es de entorno químico, no de multiplicidad.
- La fusión =Cq/Ar + C=O en Cqsp2 eliminó la ambigüedad estructural irresoluble y aportó +4.25 pp.

5.2 Próximos Pasos para Superar el 85%

1. **Resolver la confusión alifático/heteroatómico** (nueva prioridad):
 - Añadir el número de heteroátomos totales (O+N) como condicionante.
 - Restricción en postprocesamiento usando la fórmula para acotar cuántos CH_n-X son plausibles.
2. **Inyección del DBE** (Grado de Insaturación): diferencia C=O de aromáticos dentro de Cqsp2; ya calculable desde la fórmula disponible.
3. **Evaluar fusión de Aldeh. en Cqsp2:** el 77% de sus errores van a =CH/Ar; puede simplificar el problema sin perder información.
4. **Resolver el V4 con Curriculum Learning:** pre-entrenar la rama 1D antes de activar el HSQC de 2 canales.