

Proyecto: Elucidación Estructural RMN 1D/2D mediante Deep Learning

Reporte Comparativo de Evaluación
Modelos V3 $\rightarrow$ V8

Lucas Passaglia

Abril 2026

Contents


1	Resumen Ejecutivo	2
2	Arquitectura Común y Progreso de Modelos (V3–V6)	2
2.1	Evolución de condicionantes y resultados (V3–V6)	3
3	Mejor Modelo Previo: V6 con 12 Clases (83.79%)	3
3.1	Motivación: Fusión de =Cq/Ar y C=O en Cqsp2	3
3.2	Convergencia del Entrenamiento	3
3.3	MAE por Grupo — V6 12 clases	4
3.4	Análisis de Errores del V6 12 clases	4
3.4.1	Errores de Multiplicidad	4
3.4.2	Errores de Entorno Químico	5
4	V7_FM_17v: Separación de Entornos O/N (83.36%)	5
4.1	Motivación: Desambiguación de Heteroátomos	5
4.2	Resultados y MAE por Grupo	5
4.3	Errores por Entorno	5
4.4	Confusiones Dominantes	5
4.5	Diagnóstico del Scheduler	6
4.6	Propuesta: Vector de 19 Variables	7
5	V8: HSQC de 2 Canales con Integración de H (en curso)	7
5.1	Motivación	7
5.2	Nuevo Dataset: nmr_dataset_v3	7
5.3	Cambios en la Arquitectura	8
5.4	Scheduler Corregido	8
5.5	Variante V8b (planificada)	8
5.6	Resultados	8
6	Conclusiones y Próximos Pasos	8
6.1	Hitos del Proyecto	8
6.2	Próximos Pasos	9

1 Resumen Ejecutivo

Este reporte consolida los resultados de todos los modelos entrenados sobre 144.280 moléculas (set de validación hermético: 14.428, semilla fija `set_seed(42)`). La métrica principal es el **Exact Match Accuracy (EMA)**: porcentaje de moléculas cuyo vector de grupos funcionales es predicho perfectamente.

Table 1: Serie completa de modelos

Modelo	Condicionantes inyectados	EMA	Δ base	Clase
V3 — base	Espectros + total señales	72.42%	—	13
V4 — 2 canales	Espectros 2ch + total señales	69.86%	−2.56 pp	13
V5 — base + CH2	Espectros + total señales + total CH2	74.86%	+2.44 pp	13
V6 — completo (+FM)	Espectros + señales + CH2 + FM	79.54%	+7.12 pp	13
V6 12v — simple	V6 + fusión Cqsp2	83.74%	+11.32 pp	12
V6 12v — doble	V6 + fusión Cqsp2 + ajuste CH2	83.79%	+11.37 pp	12
V7_FM_17v	V6 FM + vector 17v (O/N separados)	83.36%	+10.94 pp	17
V8	HSQC 2ch integrado + vector 17v (sin FM)	en curso	—	17
<i>Objetivo del proyecto</i>		>85%		



2 Arquitectura Común y Progreso de Modelos (V3–V6)

Todos los modelos comparten la misma arquitectura base de dos ramas: una rama convolucional para el HSQC ($3 \times \text{Conv2D}$ con $16 \rightarrow 32 \rightarrow 64$ filtros + MaxPool, salida aplanada de 65.536 neuronas) y una rama densa para las proyecciones 1D (`vec_c` + `vec_h`, $512 \rightarrow 256 \rightarrow 128$ neuronas). Ambas se concatenan junto a un tensor condicional variable y pasan por capas densas de fusión. La función de pérdida penaliza el error individual por grupo y la desviación en el total de señales:

$$\mathcal{L} = \text{MSE}(\hat{y}, y) + 0.5 \cdot \text{MSE}\left(\sum_i \hat{y}_i, \sum_i y_i\right) \quad (1)$$

2.1 Evolución de condicionantes y resultados (V3–V6)

Cada versión añadió conocimiento químico explícito como condicionante, siendo esa la palanca más efectiva de mejora a lo largo de la serie.

V3 (72.42%) — condicionante mínimo: solo el total de señales. Línea base real tras corregir la fuga de datos que inflaba el rendimiento a 89.26%.

V4 (69.86%) — HSQC de 2 canales (señales positivas/negativas separadas). Peor resultado de la serie por colapso de modalidad: la imagen segregada resuelve sola los carbonos con H y la red deja de optimizar la rama 1D. Requiere Curriculum Learning para funcionar.

V5 (74.86%) — segundo condicionante: total de señales CH2 (+2.44 pp).

V6 (79.54%) — fórmula molecular completa [C, H, N, O, S, Hal] vía RDKit, más regularización (Dropout 0.25 + Weight Decay 10^{-5}). Mayor salto de la serie (+7.12 pp).

V6 12 clases (83.79%) — fusión de =Cq/Ar y C=O en Cqsp2, eliminando la ambigüedad irresoluble entre carbonos cuaternarios sp2 invisibles en HSQC. Aporta +4.25 pp.

Table 2: Comparativa de MAE por grupo (V3 $\rightarrow$ V6)

Grupo	V3	V4	V5	V6	Δ V3 $\rightarrow$ V6
CH3	0.0161	0.0195	0.0156	0.0116	−27.9%
CH2	0.0444	0.0532	0.0341	0.0292	−34.2%
CH	0.0381	0.0442	0.0365	0.0304	−20.2%
Cq	0.0299	0.0347	0.0305	0.0268	−10.4%
CH3-X	0.0147	0.0166	0.0112	0.0110	−25.2%
CH2-X	0.0391	0.0461	0.0381	0.0331	−15.3%
CH-X	0.0434	0.0473	0.0390	0.0308	−29.0%
Cq-X	0.0448	0.0449	0.0396	0.0365	−18.5%
=CH2	0.0046	0.0050	0.0040	0.0034	−26.1%
=CH/Ar	0.0647	0.0657	0.0536	0.0462	−28.6%
=Cq/Ar	0.1663	0.1819	0.1487	0.1141	−31.4%
Aldeh.	0.0145	0.0153	0.0115	0.0116	−20.0%
C=O	0.1198	0.1348	0.1123	0.0742	−38.1%

3 Mejor Modelo Previo: V6 con 12 Clases (83.79%)

3.1 Motivación: Fusión de =Cq/Ar y C=O en Cqsp2

El análisis del V6 mostró que la confusión =Cq/Ar $\leftrightarrow$ C=O concentraba el 53–80% del error de ambos grupos. Ambos comparten invisibilidad en HSQC (carbonos cuaternarios sp2 sin H), desplazamiento ^{13}C solapado en la región 100–165 ppm, y ausencia de discriminador disponible con la información espectral provista. La fusión en Cqsp2 aportó +4.25 pp de EMA.

3.2 Convergencia del Entrenamiento

El entrenamiento fue interrumpido a los 61 epochs por límites del clúster, pero el mejor checkpoint se obtuvo en el epoch 42 (Val Loss: 0.0297). Desde el epoch 47 el val loss se

estabilizó en ~ 0.0307 con $LR \rightarrow 0.000031$ sin mejora adicional.

Table 3: Evolución del entrenamiento V6 12 clases

Epoch	Train Loss	Val Loss	Nota
1	0.8670	0.2046	
10	0.0341	0.0397	
32	0.0121	0.0307	
42	0.0067	0.0297	Mejor checkpoint
54	0.0042	0.0307	LR = 0.000063 (plateau)
61	0.0037	0.0307	Job interrumpido

3.3 MAE por Grupo — V6 12 clases

Table 4: MAE por grupo — V6 12 clases (EMA: 83.79%)

Grupo	Descripción	MAE	Estado
CH3	Metilo alifático	0.0122	Excelente
CH2	Metileno alifático	0.0358	Excelente
CH	Metino alifático	0.0321	Excelente
Cq	Cuaternario alifático	0.0279	Excelente
CH3-X	Metilo heteroatómico	0.0122	Excelente
CH2-X	Metileno heteroatómico	0.0385	Excelente
CH-X	Metino heteroatómico	0.0349	Excelente
Cq-X	Cuaternario heteroatómico	0.0404	Excelente
=CH2	Metileno vinílico	0.0037	Excelente
=CH/Ar	Aromático / Vinílico CH	0.0476	Excelente
Cqsp2	Cuaternario sp2 (arom.+olef.+C=O)	0.0618	Aceptable
Aldeh.	Aldehído (CHO)	0.0119	Excelente

Hito: por primera vez todos los grupos por debajo de MAE 0.1.

3.4 Análisis de Errores del V6 12 clases

3.4.1 Errores de Multiplicidad

Table 5: Moléculas con al menos un error de multiplicidad (serie completa)

Modelo	Mol. afectadas	%	Tendencia
V3 (base, 13 clases)	161	1.1%	línea base
V5 (+ CH2)	116	0.8%	−0.3 pp
V6 (completo, 13 clases)	86	0.6%	−0.5 pp
V6 12v (doble restricción)	104	0.7%	prácticamente resuelto

Table 6: Moléculas con al menos un error en cada entorno — V6 12 clases

Entorno	Mol. con error	%	MAE medio
Alifáticos (sp ³)	1.349	9.3%	0.0270
Heteroatómicos (sp ³ -X)	1.627	11.3%	0.0315
Carbonos sp ² (Cqsp ² , =CH/Ar, Aldeh.)	1.295	9.0%	0.0313
Moléculas perfectas (EMA)	12.098	83.79%	

3.4.2 Errores de Entorno Químico

4 V7_FM_17v: Separación de Entornos O/N (83.36%)

4.1 Motivación: Desambiguación de Heteroátomos

En el V6, los grupos con heteroátomo se representaban con una única clase por multiplicidad (CH-X, CH₂-X, etc.), sin distinguir si el heteroátomo era oxígeno o nitrógeno. El V7 extiende el vector de 12 a **17 clases** separando explícitamente los entornos O y N, y además independiza aldehído e imina que en el V6 quedaban fusionados en Cqsp²:

Índ.	Grupo	Índ.	Grupo
0	CH ₃	9	CH ₂ -N
1	CH ₂	10	CH-N
2	CH	11	Cq-N
3	Cq	12	=CH ₂
4	CH ₃ -O	13	=CH/Ar
5	CH ₂ -O	14	Cqsp ²
6	CH-O	15	Aldeh
7	Cq-O	16	Imina
8	CH ₃ -N		

4.2 Resultados y MAE por Grupo

EMA: 83.36% — una reducción de 0.43 pp respecto al V6 12 clases. Esta caída es esperada y no indica regresión: pasar de 12 a 17 clases eleva la barra del exact match (hay 5 valores más que acertar por molécula). Los grupos nuevos muestran MAE excelente desde la primera ejecución.

Destacado: los entornos con oxígeno y nitrógeno tienen **menos error que los alifáticos puros** (6.3% y 6.9% vs 8.5%), lo que confirma que la red aprovecha la fórmula molecular para anclarlos correctamente.

4.3 Errores por Entorno

4.4 Confusiones Dominantes

Las principales confusiones residuales son cruzadas entre entornos O y N:

- CH₂ → CH₂-N: 171 señales (69% de sus errores). Bidireccional.

Table 7: MAE por grupo — V7_FM_17v (EMA: 83.36%)

Grupo	MAE	Estado
CH3	0.0138	Excelente
CH2	0.0285	Excelente
CH	0.0335	Excelente
Cq	0.0259	Excelente
CH3-O	0.0039	Excelente
CH2-O	0.0146	Excelente
CH-O	0.0265	Excelente
Cq-O	0.0261	Excelente
CH3-N	0.0062	Excelente
CH2-N	0.0333	Excelente
CH-N	0.0234	Excelente
Cq-N	0.0154	Excelente
=CH2	0.0026	Excelente
=CH/Ar	0.0510	Aceptable
Cqsp2	0.0614	Aceptable
Aldeh	0.0039	Excelente
Imina	0.0103	Excelente

Table 8: Errores por entorno — V7_FM_17v

Entorno	Mol. con error	%	MAE medio
Alifáticos (sp3)	1.232	8.5%	0.0254
Con oxígeno (sp3-O)	915	6.3%	0.0178
Con nitrógeno (sp3-N)	1.000	6.9%	0.0196
sp2	1.352	9.4%	0.0258

- CH2-N $\rightarrow$ CH2: 180 señales (54%).
- CH2-O $\rightarrow$ CH2-N: 49 señales (37.7%).
- Imina $\rightarrow$ =CH/Ar: 80 señales (71.4%).

La confusión O/N tiene causa espectral: el desplazamiento ^{13}C de CH2 alfa a oxígeno y alfa a nitrógeno se solapa en región 40–80 ppm y la fórmula molecular sólo informa conteos totales, no conectividad local.

4.5 Diagnóstico del Scheduler

El scheduler ReduceLR0nPlateau con `patience=3`, `factor=0.5` fue demasiado agresivo para 17 clases: el LR quedó en 0.000000 desde el epoch 74, y el modelo corrió 26 epochs sin ningún cambio de pesos. El mejor checkpoint se obtuvo en el epoch 34 (Val Loss 0.0229).

4.6 Propuesta: Vector de 19 Variables

Para atacar la confusión alifático/heteroatómico residual, se propone extender el vector de 17 a **19 clases** añadiendo dos grupos nuevos que codifican conectividad múltiple a heteroátomos:

Índ.	Grupo (nuevo)
17	C-2X — carbono sp ³ unido a dos heteroátomos (acetal, aminoácido, etc.)
18	C-3X — carbono sp ³ unido a tres heteroátomos (ortoformiato, etc.)

Estos grupos presentan desplazamientos de ¹³C muy característicos (acetales: 95–105 ppm; C-3X: 105–115 ppm) que hoy quedan enmascarados en las clases CH-O o Cq-O. Su separación explicitítica debería reducir la confusión cruzada sp³-O ↔ sp³-N y aportar información discriminante para Cqsp².

5 V8: HSQC de 2 Canales con Integración de H (en curso)

5.1 Motivación

El V4 demostró que los 2 canales HSQC *mal implementados* dañan el rendimiento por colapso de modalidad. El V8 ataca el mismo problema con una implementación cualitativamente distinta, basada en un nuevo generador de mapas (`Genera_mapas_de_pk1_v2.py`).

5.2 Nuevo Dataset: `nmr_dataset_v3`

El dataset `nmr_dataset_v3_144280.h5` incorpora tres cambios respecto al original:

1. **Canal 0 — DEPT escalado por N_H** : la amplitud de cada pico es $\pm N_H$ del carbono (CH₂ negativo). CH₃ aporta amplitud +3, CH₂ aporta −2, CH aporta +1. Antes era ± 1 fijo.
2. **Canal 1 — Tipo CH normalizado (nuevo)**: valor proporcional al número de H del carbono: CH = 0.33, CH₂ = 0.67, CH₃ = 1.0. Este canal le aporta a la red información directa de multiplicidad sin depender del signo.
3. **vec_h con integración proporcional**: la amplitud del pico en el vector de proyección 1H es proporcional a N_H , replicando la integración real de un espectro ¹H.
4. **vec_c con binning no uniforme**: más resolución en la zona alifática (0–90 ppm → 128 bins) y menos en carbonilo (160–220 ppm → 32 bins).

El canal 2 es el cambio más significativo: codifica directamente si una señal es CH, CH₂ o CH₃, información que en el V6/V7 solo estaba disponible implícitamente vía el signo del DEPT.

5.3 Cambios en la Arquitectura

- **Conv2d(1 → 2)**: primera capa convolucional acepta 2 canales.
- **fusion_dim**: $65536 + 128 + 2$ (sin fórmula molecular en esta variante).
- **Condicionante reducido**: [total_señales, total_CH2], 2 valores en lugar de 8. La hipótesis es que el canal 1 del HSQC reemplaza funcionalmente a la fórmula molecular para la discriminación de multiplicidad.

5.4 Scheduler Corregido

En respuesta al diagnóstico del V7, el scheduler pasa a **patience=8**, **factor=0.7**, lo que permite al menos 80 epochs útiles de entrenamiento.

5.5 Variante V8b (planificada)

Una vez completado el V8 base, se evaluará **V8b**: mismo dataset y arquitectura pero reincorporando la fórmula molecular completa al condicionante (8 valores). La comparación directa V8 vs V8b permitirá cuantificar el aporte marginal de la fórmula molecular cuando el canal 2 ya aporta información de multiplicidad.

5.6 Resultados

Entrenamiento en curso. Resultados pendientes.

6 Conclusiones y Próximos Pasos

6.1 Hitos del Proyecto

- **83.79% EMA** (V6 12 clases): máximo absoluto sobre 12 clases, a 1.21 pp del objetivo de 85%.
- Todos los grupos por debajo de MAE 0.1 por primera vez.
- El error de multiplicidad (CH/CH2/CH3) está prácticamente resuelto (>99.5% de precisión en todos los entornos).
- La separación O/N en el V7 confirmó que la red puede distinguir entornos heteroatómicos con excelente MAE (<0.034) desde el primer entrenamiento.
- La fusión =Cq/Ar + C=O en Cqsp2 eliminó la ambigüedad estructural irresoluble (+4.25 pp).
- La inyección de conocimiento químico explícito como condicionante fue consistentemente la estrategia más efectiva.

6.2 Próximos Pasos

1. **V8 — resultado esperado:** el canal 2 del HSQC aporta información de multiplicidad directa que debería reducir la confusión CH/CH₂/CH₃ residual y potencialmente superar el 85%.
2. **V8b — ablación de FM:** comparar V8 con y sin fórmula molecular para cuantificar su aporte marginal en presencia del canal 2.
3. **Vector 19v — C-2X y C-3X:** extender el vector de 17 a 19 clases con carbonos doblemente y triplemente heteroatómicos para atacar la confusión sp³-O ↔ sp³-N residual del V7.
4. **Scheduler robusto:** usar `patience=8`, `factor=0.7` en todos los entrenamientos futuros para evitar el colapso de LR prematuro observado en V7.
5. **V4 con Curriculum Learning:** pre-entrenar la rama 1D antes de activar el HSQC de 2 canales para evitar el colapso de modalidad.